# Paso 1) Funcionamiento básico con PySpark

En primer lugar, debe inicializar el SQLContext aún no está iniciado.

```
#from pyspark.sql import SQLContext
url = "https://raw.githubusercontent.com/guru99-edu/R-Programming/master/adult_data.csv"
from pyspark import SparkFiles
sc.addFile(url)
sqlContext = SQLContext(sc)
```

luego, puede leer el archivo cvs con SQLContext.read.csv. Utilice InferSchema establecido en True para indicar a Spark que adivine automáticamente el tipo de datos. De forma predeterminada, se convierte en False.

```
df = sqlContext.read.csv(SparkFiles.get("adult_data.csv"), header=True, inferSchema=
True)
```

### Echemos un vistazo al tipo de datos

```
df.printSchema()
root
 -- age: integer (nullable = true)
 -- workclass: string (nullable = true)
 -- fnlwgt: integer (nullable = true)
 -- education: string (nullable = true)
 -- education num: integer (nullable = true)
 -- marital: string (nullable = true)
 -- occupation: string (nullable = true)
 -- relationship: string (nullable = true)
 -- race: string (nullable = true)
 -- sex: string (nullable = true)
 -- capital gain: integer (nullable = true)
 -- capital loss: integer (nullable = true)
 -- hours week: integer (nullable = true)
 -- native country: string (nullable = true)
 -- label: string (nullable = true)
```

Puedes ver los datos con show.

```
df.show(5, truncate = False)
```

age workclass	fnlwgt educati	on educatio	n_num marital		occupation
relationship  rac	ce  sex  capital_	gain capita	l_loss hours_	week native	_country label
++	+	+	+		+
-++	+	+	+	+	+
39  State-gov	9   State-gov   77516   Bachelors   13		Never-m	Never-married   Adm-clerical	
Not-in-family Wh:	ite Male  2174	0	40	United	l-States  <=50K
50  Self-emp-not-inc 83311  Bachelors 13			Married-civ-spouse Exec-manageria		
Husband  Wh:	ite Male  0	10	13	United	l-States  <=50K
38  Private	215646 HS-grad	9	Divorce	d	Handlers-
cleaners Not-in-fa	amily White Male	0	0	40	United-States
<=50K					
53  Private	234721 11th	7	Married	Married-civ-spouse Handlers-	
cleaners   Husband	Black Male	0	0	40	United-States
<=50K					
28   Private	338409 Bachelo	rs 13	Married	Married-civ-spouse Prof-specialty	
Wife  Bla	ack Female 0	10	40	Cuba	<=50K
++	+	+	+		+

Si no configuró IndersHema en True, esto es lo que está sucediendo con el tipo. Hay todos en cadena.

```
df string = sqlContext.read.csv(SparkFiles.get("adult.csv"), header=True, inferSchema=
False)
df string.printSchema()
root
 -- age: string (nullable = true)
  -- workclass: string (nullable = true)
  -- fnlwgt: string (nullable = true)
  -- education: string (nullable = true)
  -- education num: string (nullable = true)
  -- marital: string (nullable = true)
  -- occupation: string (nullable = true)
  -- relationship: string (nullable = true)
  -- race: string (nullable = true)
  -- sex: string (nullable = true)
  -- capital gain: string (nullable = true)
  -- capital loss: string (nullable = true)
  -- hours week: string (nullable = true)
  -- native country: string (nullable = true)
 -- label: string (nullable = true)
```

Para convertir la variable continua en el formato correcto, puede usar la refundición de las columnas. Puede usar WithColumn para indicar a Spark qué columna operar la transformación.

```
# Import all from `sql.types`
from pyspark.sql.types import *
# Write a custom function to convert the data type of DataFrame columns
def convertColumn(df, names, newType):
    for name in names:
        df = df.withColumn(name, df[name].cast(newType))
    return df
# List of continuous features
CONTI FEATURES = ['age', 'fnlwgt', 'capital gain', 'education num', 'capital loss',
'hours week']
# Convert the type
df string = convertColumn(df string, CONTI FEATURES, FloatType())
# Check the dataset
df string.printSchema()
root
 |-- age: float (nullable = true)
 |-- workclass: string (nullable = true)
 |-- fnlwgt: float (nullable = true)
 |-- education: string (nullable = true)
 |-- education num: float (nullable = true)
 |-- marital: string (nullable = true)
 |-- occupation: string (nullable = true)
 |-- relationship: string (nullable = true)
 |-- race: string (nullable = true)
 |-- sex: string (nullable = true)
 |-- capital gain: float (nullable = true)
 -- capital loss: float (nullable = true)
 |-- hours week: float (nullable = true)
 |-- native country: string (nullable = true)
 |-- label: string (nullable = true)
```

```
#stringIndexer = StringIndexer(inputCol="label", outputCol="newlabel")
#model = stringIndexer.fit(df)
#df = model.transform(df)
df.printSchema()
```

from pyspark.ml.feature import StringIndexer

## Seleccionar columnas

Puede seleccionar y mostrar las filas con selección y los nombres de las entidades. A continuación, se seleccionan edad y fnlwgt.

```
df.select('age','fnlwgt').show(5)
```

```
+---+----+
|age|fnlwgt|
+---+----+
| 39| 77516|
| 50| 83311|
| 38|215646|
| 53|234721|
| 28|338409|
+---+-----+
only showing top 5 rows
```

#### Recuento por grupo

Si desea contar el número de ocurrencia por grupo, puede encadenar:

- GrupoPor ()
- count ()

juntos. En el ejemplo siguiente, cuenta el número de filas por nivel educativo.

```
df.groupBy("education").count().sort("count",ascending=True).show()
```

```
education | count |
   Preschool 51
     1st-4th | 168|
     5th-6th 333
   Doctorate 413
        12th | 433 |
         9th 514
 Prof-school 576
     7th-8th| 646|
        10th | 933 |
  Assoc-acdm | 1067|
        11th | 1175|
   Assoc-voc | 1382|
     Masters | 1723|
   Bachelors | 5355|
|Some-college| 7291|
     HS-grad | 10501 |
+----+
```

#### Describir los datos

Para obtener un resumen de estadísticas, de los datos, puede utilizar describe (). Se calculará el:

- conteo
- significar
- · desviación estándar
- mín
- Máx

```
df.describe().show()
```

```
-----+
                   age | workclass
                                  fnlwgt| education|
summary
education num | marital | occupation | relationship |
                                                      race
                                                            sex
capital gain | capital loss |
                           hours week native country label
                 32561
                       32561
                                                     32561
count
                                      32561
                                              32561 32561
32561 32561
                     32561 32561
32561
             32561
                    32561
                                        32561 | 32561 |
mean 38.58164675532078 null 189778.36651208502
                                                      null
10.0806793403151 null|
                              null
                                         null
                                                        null
null | 1077.6488437087312 | 87.303829734959 | 40.437455852092995 |
                                                        null | null |
stddev 13.640432553581356 null 105549.97769702227
null|2.572720332067397| null|
                                   null
                                              null
                                                             null null
7385.292084840354 | 402.960218649002 | 12.347428681731838 |
                                                   null | null |
                   17|
                                          12285
                                                      10th
    min
                    ?
1 Divorced
                          Husband | Amer-Indian-Eskimo | Female |
                                                                    0
```

Si desea que la estadística de resumen de una sola columna, agregue el nombre de la columna dentro de describe ()

```
df.describe('capital_gain').show()
```

#### Filtrar datos

Puede utilizar filter () para aplicar estadísticas descriptivas en un subconjunto de datos. Por ejemplo, puede contar el número de personas mayores de 40 años

```
df.filter(df.age > 40).count()
```

13443

## Estadísticas descriptivas por grupo

Finalmente, puede agrupar datos por grupo y calcular operaciones estadísticas como la media.

```
df.groupby('marital').agg({'capital_gain': 'mean'}).show()
```